

Machine Learning

EMSI - Université Côte d'Azur
Richard Grin
Version 1.40 - 26/10/25

1

Objectif du cours

- Ce cours « Agents conversationnels en Java avec LangChain4j » fait partie du parcours MIAGE « Intelligence Artificielle Appliquée » (IA2)
- Il est essentiellement **pratique** en montrant comment tirer profit de LMs dans les applications d'entreprise, en utilisant l'**API** de ces modèles
- LM : *Language Model* ; modèle de langage utilisé, par exemple, par ChatGPT et Gemini
LLM : *Large Language Model*

R. Grin

ML

2

2

Examen

- Durée 2 heures, sans documents
- Vous choisissez la date, avec l'administration de l'EMSI ; au moins 15 jours après la fin du cours, pour avoir le temps de finir les TPs car des questions pourront porter sur les TPs
- Le délégué me tient au courant assez rapidement
- Les bonus sont ajoutés à la note de l'examen pour avoir la note finale

R. Grin

ML

3

3

TPs

- **Indispensables** pour assimiler le cours
- Copier-coller du code sans essayer de le comprendre ne vous servira à rien, en particulier pour l'examen
- Vous pourrez terminer les TPs après mon départ et avant l'examen
- Bonus pour les TPs terminés avant la date limite
- Travail personnel
 - Vous pouvez demander des explications à votre entourage ou à une IA, mais **vous devez écrire le code seul(e)**, en suivant ce qui est demandé dans les énoncés (peu de choses le plus souvent)
 - **INTERDIT** de consulter les dépôts GITHUB des autres étudiants

R. Grin

ML

page 4

4

Bonus

- Pour la réactivité : réponse aux emails en respectant les formats demandés, installation des logiciels, TPs terminés,...
- Pour les réponses aux questions pendant le cours
- Pour les questions intéressantes
- Retenez votre numéro dans la liste ; vous appellerez ce numéro
 - si vous avez un bonus
 - dans vos emails
- Malus pour retards, manque de travail manifeste, triche, pas pour mauvaises réponses ou questions

R. Grin

ML

page 5

5

Sujet email

- [EMSI-IA-G?] xxxxx - nn
 - avec [EMSI-IA-G?] **sans espaces**

R. Grin

ML

6

6

Indispensable pour bonus TPs

- Faire tous les **commits** (ou presque...)
- Lire **attentivement** et suivre ce qui est demandé pour le bonus
- En particulier, les **informations demandées dans les emails** sont indispensables et elles ne doivent apparaître nulle part ailleurs (pas dans le README GitHub par exemple)

R. Grin

ML

7

7

Les erreurs les plus communes

- Ne pas vérifier que les **pushs** ont été effectués
- Mauvaise version de Java (pom.xml)
- Mauvaise version de LangChain4j
- Plugins Maven pas à jour
- Pas de .gitignore pour Git
- Mauvais packages pour les classes
- Récrire le code fourni dans les TPs sans expliquer la raison de cette réécriture (il doit y avoir une raison importante)

R. Grin

ML

8

8

Comment demander de l'aide à l'enseignant ou sur le Web

- Lisez attentivement cette page : <http://richard.grin.free.fr/emsi/casablanca-ia/tp/demandeaide.html>
- En résumé :
 - N'envoyez pas de copie d'écran, sauf exception
 - Le minimum d'information à fournir :
 - environnement d'exécution (version de l'OS et des logiciels,...)
 - étapes qui ont conduit au problème
 - message d'erreur (et logs)

R. Grin

ML

page 9

9

Supports du cours

- Premier support rappelle quelques généralités et concepts importants du machine learning et du deep learning
- Deuxième support sur les embeddings et l'utilisation des LMs
- Troisième support sur LangChain4j, le framework standard de facto pour utiliser les LMs avec du code Java ; il est utilisé dans les TPs
- Dernier support sur le fine tuning et le RAG qui permettent d'améliorer les réponses des LMs

R. Grin

ML

10

10

Plan de ce support

- Généralités sur l'IA
- Machine learning
- Réseaux de neurones
- Transformeurs
- Références

R. Grin

ML

11

11

Intelligence artificielle

R. Grin

ML

12

12

Définitions

- IA : ensemble des théories et techniques visant à réaliser des machines capables de simuler l'intelligence humaine (Wikipedia)
- Le but est d'automatiser, de rendre plus rapides et plus efficaces des tâches qui demandent de l'intelligence
- Intelligence : capacité à comprendre, apprendre, s'adapter et résoudre des problèmes dans un environnement donné

R. Grin

ML

13

13

Types d'IA

- IA « classique » : s'appuie sur des règles et des connaissances fournies par des experts humains ; produit typiquement des systèmes experts
- Apprentissage automatique (Machine learning, ML) : développe des modèles capables d'apprendre seuls à partir de données d'entraînement
 - pour ensuite faire des prédictions et prendre des décisions
 - sans que les règles utilisées ne soient fournies par des humains

R. Grin

ML

14

14

Machine learning

R. Grin

ML

15

15

Présentation

- 2 phases bien distinctes :
 - Durant la **phase d'apprentissage** on part d'un **modèle** (logiciel) *non entraîné* qu'on entraîne à fournir des bonnes réponses à partir d'exemples (*dataset*)
 - Durant l'**inférence**, le modèle entraîné est utilisé pour prévoir des résultats, sur de nouvelles données
- L'apprentissage est souvent très lourd et coûteux mais ne se fait qu'une seule fois ; nécessite des machines très puissantes, avec GPU ou NPU (on peut en louer sur le cloud si utilisation peu fréquente)

R. Grin

ML

16

16

Modèle

- Logiciel qui permet de faire des prédictions ou de prendre des décisions
- Représentation mathématique $y = f(x_1, \dots, x_n)$; trouver un résultat y à partir des données d'entrée x_i
 - Pour le type régression, y est numérique (valeur simple, vecteur,...)
 - Pour le type catégoriel, y est une catégorie (classification)
 - Pour le type génératif, y peut être du texte, une image, une vidéo, du son,...

R. Grin

ML

17

17

Exemples d'apprentissage

- Avec les exemples le modèle va apprendre à reproduire le bon comportement
- Chaque exemple est composé
 - de valeurs x_1, \dots, x_n en entrée
 - d'une réponse y attendue pour ces valeurs en entrée
- Pour chaque exemple, **le fonctionnement du modèle est ajusté pour que le y calculé soit le plus proche possible de la réponse attendue**
- Pour éviter le bruit (un exemple peut être aberrant), on regroupe souvent les exemples dans des *batches* (groupe de quelques dizaines à quelques centaines d'exemples)

R. Grin

ML

18

18

Exemples pour la validation

- Lorsqu'on entraîne un modèle, il est important de ne pas utiliser toutes les données pour l'apprentissage
- On divise le jeu de données en deux parties :
 - les données d'entraînement, utilisées pour apprendre le modèle
 - les données de validation (ou de test), mises de côté pour évaluer le modèle après l'apprentissage
- On teste ainsi, sur des exemples qu'il n'a jamais vus, la capacité du modèle à généraliser à des nouvelles situations

R. Grin

ML

19

19

Types de machine learning

- Dans le ML « classique », le *data scientist* choisit un type de modèle à utiliser (modèle linéaire, polynomial, arbre de décision, clustering, par exemple)
- L'apprentissage profond (deep learning, DL) a pour modèle un réseau de neurones

R. Grin

ML

20

20

Data scientist

- Expert en science des données
- Spécialiste capable d'extraire de la valeur à partir de données brutes
- En ML, ses tâches principales sont
 - choix et préparation des données d'entraînement
 - choix du type de modèle
 - évaluation du modèle

R. Grin

ML

21

21

IA générative (*GenAI*)

- Branche du DL qui génère des contenus nouveaux
- Les **LLMs** (*Large Language Models*) sont les logiciels d'IA générative les plus utilisés (ChatGPT, Gemini,...) ; ils permettent de traiter les langages naturels (français, anglais, arabe, ...) : chat avec les utilisateurs, traduction de texte, aide au codage, ...
- Des logiciels d'IA générative peuvent générer du texte mais aussi du code, des images, de la musique, des vidéos, ... ; on parlera alors de LLMs **multimodaux** ou de **modèles de base**

R. Grin

ML

22

22

Cas d'utilisation

- ML « classique », souvent avec des données structurées :
 - Prédiction de défauts de paiement (finance)
 - Classification de patients à risque (santé)
 - Décider si un email est un spam
 - Optimisation des stocks
- DL, souvent sur des données complexes, volumineuses, non structurées (textes, images, sons) :
 - Traitement du langage naturel (traduction, chatbot)
 - Vision par ordinateur (reconnaissance faciale, détection d'objets, diagnostic médical par imagerie)
 - Voitures autonomes, robots « intelligents »

R. Grin

ML

23

23

Exemples de types de modèles

- Linéaire - fonction linéaire entre les variables d'entrée et de sortie (exemple : régression linéaire)
- Arbre de décision - utilise une structure d'arbre pour prendre des décisions
- Clustering - regroupe des données en clusters (groupes) selon leur similarité, sans étiquettes prédéfinies (exemple : k-means clustering)
- Réseaux de neurones - utilise des neurones artificiels

R. Grin

ML

24

24

ML classique, DL ou GenAI ?

Exemple 1 de modèle

- Modèle qui prédit si un client est susceptible d'acheter un certain produit
- Le modèle est entraîné avec de nombreux exemples **réels** de clients, avec leurs caractéristiques (âge, groupe social ou géographique, achats déjà effectués, ...), en précisant si le client a acheté le produit
- Après l'entraînement, le modèle doit être capable de calculer la probabilité qu'un client achète le produit

R. Grin

ML

25

25

ML classique, DL ou GenAI ?

Exemple 2 de modèle

- Modèle qui donne le prix d'un appartement à afficher, compte tenu de son emplacement, de sa superficie, de son étage, de son environnement, ... pour qu'il trouve rapidement un acquéreur
- Pendant l'entraînement, on fournit au modèle les caractéristiques de très nombreux appartements qui ont été vendus, le prix de vente et le temps qu'il a fallu pour trouver un acquéreur

R. Grin

ML

26

26

ML classique, DL ou GenAI ?

Exemple 3 de modèle

- Modèle qui indique si une photo contient des installations militaires
- Pendant l'entraînement, on fournit au modèle les caractéristiques de très nombreuses photos que des hommes ont classées « militaire » ou non

R. Grin

ML

27

27

ML classique, DL ou GenAI ?

Exemple 4 de modèle

- Modèle qui génère une image à partir d'une description textuelle
- Pendant l'entraînement, on fournit au modèle des couples texte - image ; il existe des BD de tels couples

R. Grin

ML

28

28

Paramètres d'un modèle

- La plupart des types de modèle ont des paramètres définis à l'avance p_1, p_2, \dots qui déterminent le comportement du modèle
- Par exemple, si on choisit un modèle linéaire, le modèle est représenté par une fonction affine qui a 2 paramètres **a** et **b** : $f(x) = ax + b$
- Les valeurs de ces paramètres sont déterminées durant l'apprentissage pour minimiser les erreurs de prédiction sur les données d'apprentissage

R. Grin

ML

29

29

Paramètres et hyperparamètres

- Les **paramètres** d'un modèle sont *internes* au modèle ; leurs valeurs sont *automatiquement* ajustées pendant l'apprentissage ; exemple : valeurs **a** et **b** d'un modèle linéaire
- Ne pas confondre avec les **hyperparamètres** qui sont des valeurs *choisies* pour paramétrer le modèle
 - pendant l'apprentissage du modèle : taille des pas pendant la descente de gradient, nombre des couches cachées des réseaux de neurones, ...
 - pendant l'inférence : température, taille maximale de la réponse,...

R. Grin

ML

30

30

Eléments pour apprentissage

- Nombreux types d'apprentissage mais ils utilisent tous plus ou moins les mêmes éléments :
 - **Exemples d'apprentissage** ; chaque exemple est composé d'une valeur qu'on donne en entrée du modèle, et du résultat attendu pour cette entrée
 - **Modèle** ; logiciel qui apprend à partir de ces exemples
 - **Fonction de perte** ; mesure l'erreur faite par le modèle lorsqu'il est testé sur un batch d'apprentissage
 - **Algorithme d'optimisation** ; modifie le modèle pour réduire la fonction de perte sur les exemples d'apprentissage

R. Grin


ML

31

31

Exemple régression linéaire (1/2)

- **Données d'apprentissage** : points qui correspondent aux données relevées
- **Modèle** : fonction affine $f(x) = ax + b$, représentée par une droite de régression



Dessin Wikipedia

R. Grin


ML

32

32

Exemple régression linéaire (2/2)

- **Fonction de perte** : « somme des distances » des points d'un batch d'apprentissage à la droite de régression
- **Algorithme d'optimisation** : minimisation de la somme, par exemple avec une descente de gradient



R. Grin

LLM

33

33

Etapes phase d'apprentissage

1. Préparation des données d'apprentissage
2. Fixer des hyperparamètres d'apprentissage (par exemple, nombre de couches de neurones ou taux d'apprentissage)
3. Utiliser les exemples d'apprentissage pour trouver les paramètres internes du modèle
4. Validation du modèle sur les exemples de validation ; si pas de validation, on peut être amené à changer les hyperparamètres et en ce cas il faut recommencer l'étape 3

R. Grin

ML

34

34

Préparer données apprentissage

- Très important
- Les données en entrée sont souvent préparées pour supprimer le bruit et les données erronées ; par exemple suppression de balise HTML, correction fautes d'orthographe, espaces superflus, ...
- Eliminer les biais
- Gestion des données sensibles (enlever les mots de passe, les clés secrètes)
- Ajout éventuel de contexte

R. Grin

ML

35

35

Diviser données apprentissage

- En 3 groupes :
 - Le plus nombreux pour calculer les paramètres internes du modèle (par exemple 80 % des exemples)
 - Un pour trouver les meilleurs hyperparamètres d'apprentissage (10 %)
 - Le dernier pour tester l'efficacité du modèle final (10 %)

R. Grin

ML

36

36

Apprentissage (1/2)

- But : ajuster les paramètres pour le modèle
- On commence par donner des valeurs (aléatoires, si pas d'informations spéciales) aux paramètres du modèle
- Pour chaque exemple (ou groupe d'exemples, *batch*) d'apprentissage
 - La fonction de perte dépend des paramètres du modèle (calcul de la valeur de sortie du modèle) et de l'exemple (valeur en entrée et attendue en sortie)
 - L'algorithme d'optimisation modifie les paramètres du modèle pour minimiser la perte

R. Grin

ML

37

37

Apprentissage (2/2)

- Avec les nouveaux paramètres mis à jour, on refait le même processus avec l'exemple d'apprentissage suivant, et ainsi de suite, jusqu'au dernier exemple d'apprentissage (fin d'une époque)
- On peut alors commencer une nouvelle époque avec des exemples différents, ou identiques mais pas dans le même ordre
- L'apprentissage s'arrête quand la perte cesse de diminuer, pour éviter le surapprentissage (des métriques surveillent le processus)

R. Grin

ML

38

38

Surapprentissage

- Il faut savoir s'arrêter à temps dans l'apprentissage
- Si on s'arrête trop tard, on va faire du surapprentissage (overfitting) : le modèle obtenu sera surentraîné sur les données d'entraînement mais ne donnera pas des bons résultats avec d'autres données

Source images : <https://www.youtube.com/watch?v=kwgR-Qu56MA>

R. Grin

ML

39

39

Algorithme descente de gradient

- Algorithme d'optimisation qui cherche les valeurs (x_1, \dots, x_n) pour lesquelles $f(x_1, \dots, x_n)$ est minimal
- Rappel : Le gradient d'une fonction f à plusieurs variables est le vecteur de ses dérivées partielles :

$$\nabla f = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)$$

Il indique la direction où la fonction augmente le plus vite

- Si on veut minimiser la valeur de la fonction en partant d'un point (x_1, \dots, x_n) , on modifie les x_i en allant dans la direction opposée à la direction du gradient

R. Grin

ML

40

40

Fonction de perte

- La fonction de perte dépend des paramètres du modèle et des valeurs d'entrée et de sortie d'un batch d'apprentissage
- Les valeurs d'apprentissage sont fixes
- Donc, lors de la descente de gradient, on fait varier uniquement les paramètres du modèle, en les ajustant dans la direction opposée au gradient calculé par rapport à ces paramètres
- Représenter la fonction de perte comme une hypersurface aide à visualiser le principe de la descente de gradient

R. Grin

ML

41

41

Fonction de perte représentée par une hypersurface

- La fonction de perte L dépend des n paramètres du modèle et elle fournit une seule valeur (l'erreur)
- Elle peut donc être représentée par une hypersurface de dimension n dans un espace de dimension $n + 1$
- Par exemple,
 - si $n = 1$, une hypersurface est une courbe dans le plan ; fonction de perte de type $y = L(p_1)$
 - si $n = 2$, une hypersurface est une surface dans l'espace ; fonction de perte de type $y = L(p_1, p_2)$

R. Grin

ML

42

42

En dimension 2 ($n = 1$ paramètre)

- L'algorithme de la descente de gradient revient à se déplacer dans le plan (donc à modifier l'unique paramètre) *en prenant la direction de la plus grande pente descendante* pour minimiser la valeur de la fonction de perte

En dimension 2 ($n = 1$)



Valeur fonction de perte en fonction valeur paramètre

R. Grin

ML

43

En dimension 3 ($n = 2$ paramètres)




Image générée par IA

R. Grin

ML

44

Taux d'apprentissage

- La longueur du déplacement en direction de la plus grande pente est un hyperparamètre de l'algorithme d'apprentissage, qui s'appelle le *learning rate*
- Si le pas est trop petit, l'algorithme se rapproche trop lentement du minimum ; s'il est trop grand, on risque de ne pas se rapprocher du minimum (oscillation autour du minimum)

R. Grin

ML

45

Types d'apprentissages

- Supervisé (supervised learning, SL)
- Non supervisé (unsupervised learning, UL)
- Auto-supervisé (self-supervised learning, SSL)
- Par renforcement (reinforcement learning, RL)

R. Grin

ML

46

Apprentissage supervisé

- Exemples d'apprentissage **fournis par des humains** : une entrée, image, ensemble de caractéristiques (features), ... et une étiquette (label) ou variable cible en sortie
- Par exemple
 - Photos de chiens et de chats étiquetées « chien » ou « chat » par des humains
 - Prix d'appartements (variable cible) récemment vendus, avec leurs caractéristiques (étage, emplacement, superficie,...) et durée entre la mise en vente et l'achat

R. Grin

ML

47

Apprentissage non supervisé

- Le modèle doit trouver des patterns ou des relations entre des données, sans recevoir d'aide
- Les données d'entraînement ne sont pas étiquetées
- L'objectif peut être
 - d'extraire des classes d'individus présentant des caractéristiques communes (clustering) ; les définitions des classes ne sont pas données a priori
 - de trouver des associations entre les données ; par exemple indiquer que les clients qui achètent du pain achètent aussi souvent du beurre
- Moins performant que l'apprentissage supervisé mais intéressant si l'étiquetage est complexe ou coûteux

R. Grin

ML

48

Apprentissage auto-supervisé

- Intermédiaire entre apprentissage supervisé et non supervisé
- Le modèle apprend à partir d'échantillons de données non annotées ; des « étiquettes » sont générées automatiquement à partir des données d'entraînement
- Par exemple, l'entraînement d'une IA textuelle générative peut se faire en tronquant des phrases récupérées dans un livre ou sur Internet ; l'IA doit retrouver la partie cachée qui est la variable cible

R. Grin

ML

49

49

Apprentissage par renforcement

- Le logiciel apprend en interagissant avec un environnement
- Il reçoit un feedback (retour d'information) en recevant des récompenses ou des pénalités en fonction des actions qu'il entreprend dans l'environnement
- Souvent utilisé quand les données d'entraînement sont rares ; l'IA apprend par essais et erreurs

R. Grin

ML

50

50

Apprentissage par renforcement avec rétroaction humaine

- RLHF : Reinforcement Learning from Human Feedback
- Utilisé pour affiner les modèles, en particulier les LLMs
- Exemples d'interactions :
 - Des testeurs humains donnent leur avis sur les réponses des modèles
 - Plusieurs réponses peuvent être proposées aux testeurs par le modèle, en demandant la meilleure réponse
 - Demander aux testeurs de sélectionner avec la souris des objets dans une image

R. Grin

ML

51

51

Distillation des connaissances

- Apparue avec les LLMs
- Technique d'apprentissage automatique qui transfère les connaissances d'un grand modèle, le modèle « enseignant » à un modèle « élève » plus petit qui apprend à imiter les prédictions du modèle enseignant, comme avec un apprentissage supervisé
- On peut ainsi avoir un modèle plus petit, plus rapide, moins gourmand en ressources tout en gardant des connaissances proches du modèle enseignant
- Il peut y avoir des inconvénients : perte de précision par rapport à l'enseignant, reproduit les erreurs de l'enseignant, peut être difficile à optimiser

R. Grin

ML

52

52

Réseaux de neurones


R. Grin

ML

53

53

Cerveau humain



Source image : shutterstock

- 86 milliards de neurones
- Par neurone, environ 2000 dendrites (points d'entrée) ; le plus souvent un seul axone (point de sortie) mais avec plusieurs ramifications
- Chaque synapse (connexion axone-dendrite) peut être utilisée plusieurs centaines de fois par seconde
- Très efficace en énergie : consommation de 20 watts (quelques kwatts pour une IA)
- Apprendre c'est créer, supprimer des synapses, modifier leur sensibilité


R. Grin

ML

54

54

1^{ère} simulation d'un neurone : le perceptron



Frank
Rosenblatt,
1957

- Un perceptron a des paramètres P_i (**pooids**) et B (seuil ou **biais**)
- Il reçoit n valeurs X_i en entrée et calcule la somme pondérée S de ces valeurs ; la fonction d'activation retourne la valeur finale 1 si $S - B \geq 0$, et 0 sinon

R. Grin

ML

55

Neurones artificiels

- La fonction d'activation du perceptron est trop simple et elle n'est pas continue, donc pas dérivable
- Les neurones artificiels « modernes » sont des évolutions du perceptron avec, en particulier, des fonctions d'activation dérivables qui vont permettre d'utiliser la descente de gradient

R. Grin

ML

56

Fonction d'activation

- Perceptron : la sortie du perceptron est $y = H(\sum P_i X_i - B)$, avec $H(z) = 1$ si $z \geq 0$, ou 0 sinon
- Neurone artificiel : on remplace H par une fonction dérivable
- Par exemple, avec la fonction d'activation sigmoïde (d'autres choix sont possibles), la sortie du neurone est donnée par (w_i sont les poids, b est le biais)

$$y = \frac{1}{1 + e^{-(\sum w_i x_i + b)}}$$

R. Grin

ML

57

Types de fonctions d'activation

1. **Sigmoïde** : $\sigma(x) = 1 / (1 + e^{-x})$ - Produit des sorties dans la plage de 0 à 1 ; utilisée dans les couches de sortie pour les problèmes de classification binaire
2. **Tangente hyperbolique (tanh)** : $\tanh(x) = (e^{-x} - e^x) / (e^{-x} + e^x)$ - Produit des sorties dans la plage de -1 à 1, permet de gérer les valeurs négatives
3. **ReLU (Rectified Linear Unit)** : $\text{ReLU}(x) = \max(0, x)$ - Renvoie simplement zéro pour les valeurs négatives et laisse les valeurs positives inchangées. Une des fonctions d'activation les plus populaires pour les couches cachées
4. **Leaky ReLU** : $\text{Leaky ReLU}(x) = \max(\alpha x, x)$ - Variation de ReLU qui permet un faible taux de fuite (α est une petite valeur constante pour les entrées négatives) pour éviter certains problèmes liés à ReLU
5. **Softmax** : Souvent utilisée dans la couche de sortie pour les problèmes de classification multi-classes - convertit un vecteur de nombres réels en une distribution de probabilité

R. Grin

ML

58

Réseaux de neurones artificiels

- Les neurones artificiels sont regroupés en réseaux
- Ces réseaux sont structurés en couches de neurones
- Les valeurs calculées par les neurones d'une couche sont envoyées en entrée des neurones de la couche suivante

R. Grin

ML

59

Couches réseau de neurones

- La couche d'entrée est composée de neurones qui reçoivent des valeurs de l'extérieur du réseau et les transmettent aux neurones de la 1^{ère} couche cachée
- La couche de sortie fournit à l'extérieur un résultat calculé par le réseau de neurones
- Entre ces 2 couches, les couches intermédiaires, dites cachées, participent au résultat calculé par le réseau
- Souvent les neurones d'une couche sont connectés à tous les neurones de la couche précédente et de la couche suivante

R. Grin

ML

60

55

56


57

58

59

60

Exemple



R. Grin

ML

61

Paramètres du réseau

- Poids p_{ij} de toutes les liaisons entre neurones et biais b_i de tous les neurones
- Déterminent le comportement du réseau
- Calculés lors de la phase d'apprentissage en utilisant les exemples d'apprentissage



R. Grin

ML

62

Calcul des paramètres

- 2 étapes pour chaque exemple (ou groupe d'exemples) d'apprentissage :
 1. Calcul des gradients de la fonction de perte par rapport aux paramètres, par rétropropagation (*back propagation*)
 2. Ajustement des paramètres par descente de gradient, pour minimiser la fonction de perte qui calcule la distance entre
 - la valeur calculée par le réseau
 - la valeur attendue pour l'exemple d'apprentissage

R. Grin

ML

63

Rétropropagation

- Fonction de perte L ; elle dépend des matrices W_i des paramètres de la couche numéro i vers la couche numéro $i + 1$ (on suppose n couches cachées)
 - $\partial L / \partial W_{n+1}$ est d'abord calculé (W_{n+1} contient les paramètres de la dernière couche cachée vers la couche de sortie)
 - puis $\partial L / \partial W_n$ est calculé en utilisant le résultat du calcul précédent
 - et ainsi de suite pour arriver à la fin au calcul de $\partial L / \partial W_1$ (W_1 représente les paramètres de la couche d'entrée vers la 1^{ère} couche cachée)

R. Grin

ML

64



Théorème d'approximation universelle

- Rappel : un modèle d'IA peut être considéré comme une fonction $y = f(x_1, \dots, x_n)$
- Théorème : un réseau de neurones peut approcher une fonction quelconque d'autant plus près que l'on veut
- « Un réseau de neurones à une seule couche cachée, utilisant une fonction d'activation non linéaire appropriée (comme sigmoïde, tanh, ReLU...), peut approximer n'importe quelle fonction continue sur un compact de R^n , aussi précisément que l'on veut, à condition d'avoir suffisamment de neurones dans cette couche » ; https://fr.wikipedia.org/wiki/Th%C3%A9or%C3%A8me_d%27approximation_universelle

R. Grin

ML

65

Fonction approchée par un LM

- L'entraînement du LM va permettre de trouver les paramètres pour approcher une fonction qui
 - prend un texte en entrée
 - renvoie en sortie, pour chaque mot du vocabulaire, la probabilité que ce mot convienne pour compléter le texte (selon textes donnés lors de l'apprentissage du LM)

R. Grin

ML

66

Application à la génération de texte

- Le but d'un LM étant la génération de texte, la fonction approchée va être utilisée pour cette **fonction de base** :
 - prend un texte en entrée
 - renvoie en sortie un des mots les plus probables pour compléter le texte
- Pendant l'inférence, le LM va utiliser cette fonction pour générer du texte **mot par mot**
- Par exemple pour répondre à une question ou pour générer la traduction d'un texte

R. Grin

ML

67

67

Traitement des textes

- On a vu que les réseaux de neurones font des calculs sur des données **numériques** en entrée pour calculer des données en sortie
- Comment les textes sont-ils transformés en nombre pour être manipulés par les réseaux de neurones ?
- Les textes sont transformés en nombres en 2 étapes :
 - Ils sont découpés en **tokens**
 - Chaque token est ensuite transformé en un vecteur de nombres réels appelé **embedding**

R. Grin

ML

68

68

Token

- Unité minimale de texte traitée par un réseau de neurones (l'unité minimale n'est pas le mot)
- Un token peut être un mot, mais aussi une partie de mot ou un signe de ponctuation
- Il existe aussi des tokens spéciaux ; par exemple les tokens de début et de fin de génération
- La décomposition d'un mot en tokens dépend du tokenizer utilisé, logiciel qui effectue le découpage

R. Grin

ML

69

69

Exemples découpage en tokens

- Tests avec plusieurs tokenizers à l'adresse <https://huggingface.co/spaces/Xenova/the-tokenizer-playground> ; on voit que des tokenizers différents donnent souvent des découpages différents
- « smartphone » est décomposé en 2 tokens « smart » et « phone » par des tokenizers mais peut aussi ne pas être découpé
- dermatologue peut être découpé de multiples façons : der, mat, ologue, ou bien d, erm, at, olog, ue par exemple

R. Grin

ML

70

70

Exemple génération de texte pour répondre à une question

- Question « Quel est le plus grand océan du monde ? »
 - Le texte est découpé en tokens : « Quel », « est », ...
 - Le modèle génère le 1^{er} token de la réponse « L » pour compléter la question
 - Puis il génère le token « ' » qui complète « Quel est le plus grand océan du monde ? L »
 - Et ainsi de suite, pour finalement générer la réponse « L'océan Pacifique. »
 - Pour finir, le token généré suivant est le token spécial qui indique que la génération est terminée

R. Grin

ML

71

71

Vocabulaire

- C'est l'ensemble des tokens utilisés dans une langue (ou dans plusieurs langues)

R. Grin

ML

72

72

Embedding

- Chaque token est ensuite traduit en un vecteur de nombres réels, appelé embedding
- Le passage aux embeddings va permettre
 - d'effectuer des calculs mathématiques sur les données manipulées
 - mais aussi d'ajouter du sens au texte ; des tokens ayant un sens proche sont traduits par des embeddings proches (voir support suivant)



R. Grin

ML

73

73

ONNX

- Open Neural Network Exchange
- Format ouvert et open source pour représenter les modèles
- Permet d'échanger des modèles entre différents frameworks et environnements d'exécution
- Facilite l'interopérabilité entre les outils de DL comme PyTorch, TensorFlow, etc.

R. Grin

ML

74

74

Types principaux de réseaux de neurones

- De convolution (CNN ; Convolutional Neural Network)
- Récurrent (RNN ; Recurrent Neural Network)
- Transformeur

R. Grin

ML

75

75

CNN

- Type de réseau de neurones spécialement conçu pour traiter les **images**

R. Grin

ML

76

76

CNN - Filtres

- Analyse l'image par petites zones pour identifier des caractéristiques importantes (contours, texture, ...) en effectuant une opération mathématique appelée convolution
- Un CNN passe l'image d'entrée à travers plusieurs filtres pour détecter des caractéristiques de plus en plus complexes : d'abord des contours et textures de base, ensuite des formes géométriques, des objets, des visages
- Ces caractéristiques sont enregistrées dans des cartes de caractéristiques

R. Grin

ML

77

77

CNN - Pooling

- Permet de réduire la taille des cartes de caractéristiques en conservant les informations les plus importantes
- Consiste à diviser l'image en plusieurs petites zones (par exemple 2 x 2 pixels) et à remplacer la zone par un seul point avec une seule valeur pour chacune des caractéristiques
- La valeur du point peut être le max, la moyenne, ou être obtenue par une autre opération à partir des valeurs des pixels de la zone

R. Grin


ML

78

78

CNN - Réseau de neurones

- Finalement, les informations extraites des filtres et du pooling sont envoyées en entrée d'un réseau de neurones pour donner une réponse ; par exemple pour savoir si une image représente un chien, un chat ou un oiseau



R. Grin

ML

79

79

Réseaux de neurones récurrents

- Les RNNs ont été introduits pour traiter les données ordonnées en séquences : texte, image, son,...
- Le traitement utilise une chaîne de réseaux de neurones (le même réseau est utilisé dans toute la chaîne) ; à chaque étape la sortie d'un réseau de la chaîne est donnée en entrée au réseau suivant
- Exemple : 1^{er} mot d'une phrase est donné en entrée au réseau puis on donne en entrée au 2^{ème} réseau la sortie du 1^{er} réseau et le 2^{ème} mot de la phrase, etc.

R. Grin

ML

80

80

Problèmes RNNs

- Traitement séquentiel des tokens, donc apprentissage long et moins performant pendant leur utilisation
- Difficulté à capturer les relations complexes entre les éléments de la séquence ou les relations entre éléments éloignés
- Biais temporel : les premiers éléments d'une séquence sont traités différemment des derniers
- Les transformeurs réduisent fortement ces problèmes

R. Grin

ML

81

81

Transformeurs

R. Grin

ML

82

82

Présentation

- Architecture pour traiter des séquences de données ; utilise des réseaux de neurones
- Peut prendre en charge plusieurs types de données : texte, image, vidéo, série temporelle, ... ; dans la suite on se limitera aux textes
- Le module essentiel, appelée la **couche d'attention**, prend en compte les relations entre les éléments de la séquence, quelle que soit leur distance dans la séquence
- Les transformeurs ont révolutionné l'IA générative en permettant de créer des modèles très puissants de génération de texte (LLMs)

R. Grin

ML

83

83

Motivation

- La génération du mot suivant par les LMs implique une bonne compréhension du texte à compléter
- Pour cela, il ne suffit pas de comprendre chaque mot isolément
- Il faut tenir compte de la syntaxe de la langue, du contexte de chaque mot et des relations entre les mots
- Les transformeurs peuvent extraire ces informations d'un texte, et les insérer dans les embeddings

R. Grin

ML

84

84

Exemple

- « Pierre a oublié ses lunettes sur le banc sur lequel il s'était assis. »
- Un transformeur, plus précisément la couche d'attention, va capturer la relation entre « banc » et « assis », bien qu'ils soient séparés ; il a « appris » que ces mots sont souvent liés, parce qu'ils apparaissent souvent ensemble dans les phrases sur lesquelles on l'a entraîné
- Il va aussi associer « Pierre » et « il »

R. Grin

ML

85

85

Structure d'un transformeur

- Essentiellement 2 parties : **décodeur** et **encodeur**
- En fait, une pile d'encodeurs et une pile de décodeurs
- Un transformeur peut n'utiliser qu'une de ces parties ; par exemple, GPT-4 n'utilise qu'une pile de décodeurs
- L'**encodeur** enrichit une séquence d'entrée en produisant une représentation contextuelle de chaque élément de la séquence **Représentation contextuelle ?**
- Le **décodeur** génère une sortie, élément par élément

R. Grin

ML

86

86

Exemple : traduction de texte

- Traduire du texte « mot à mot » (plus exactement token par token) fournit une mauvaise traduction
- Il faut 2 étapes pour une traduction acceptable :
 1. Encodeur transforme $x = (x_1, \dots, x_n)$ en $z = (z_1, \dots, z_n)$; les z_i sont enrichis par le contexte (relations avec les autres embeddings)
 2. Décodeur génère $y = (y_1, \dots, y_m)$ à partir de z (le plus souvent $n \neq m$) ; processus autorégressif : y_p est généré en utilisant les y_i déjà générés ($i < p$), jusqu'à atteindre le token de fin

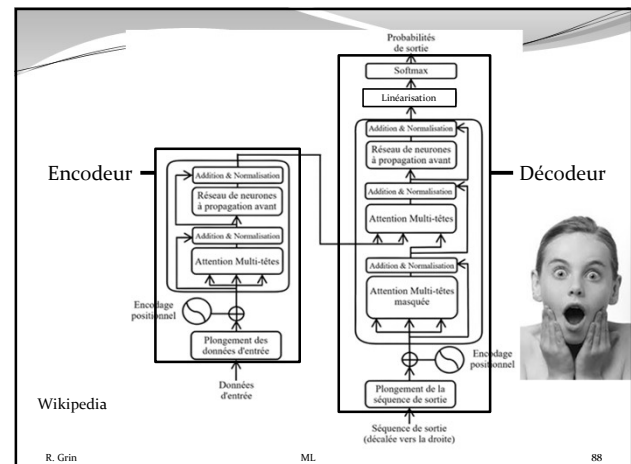
Exemple simple de traduction français-anglais avec $n \neq m$?

R. Grin

ML

87

87




R. Grin

ML

88

88

Types de traitement



R. Grin

ML

89

89

- Couche d'attention
- Réseau de neurones (Feed Forward)
- Addition et normalisation
- Chacune de ces étapes modifie les embeddings

Utilité des éléments (1/2)

- **Couche d'attention** : capture dans les embeddings les relations entre les tokens, indépendamment de leur position dans la séquence, et détermine les parties importantes de la séquence
- **Réseau de neurones (Feed-forward)** : l'étape de l'attention est linéaire (assez rigide) ; le réseau de neurones utilise sa non-linéarité pour apprendre des informations plus complexes et enrichir chaque embedding indépendamment

R. Grin

ML

90

90

Utilité des éléments (2/2)

- L'addition et la normalisation se font après chaque traitement
 - **Addition** : les données en entrée sont ajoutées aux données en sortie, ce qui évite qu'elles soient noyées dans les nouvelles données
 - **Normalisation** : évite des problèmes techniques durant l'apprentissage en réduisant les différences de grandeur entre les valeurs calculées ; évite en particulier « l'explosion » et « l'extinction » des gradients

R. Grin

ML

91

91

- La suite de ce support détaille les processus qui s'exécutent dans les transformeurs ; elle est destinée à ceux qui veulent en savoir plus, mais elle ne fait pas partie du programme à connaître pour l'examen



R. Grin

ML

92

92

Encodeur

- Transforme la séquence d'entrée (par exemple un texte qui représente une question, ou un texte à traduire) en une séquence d'embeddings
- Les embeddings sont traités en parallèle
- Utilise un mécanisme d'**attention** qui permet de s'intéresser plus particulièrement à certaines parties de la séquence d'entrée et de détecter les relations entre ces parties, même si elles sont éloignées dans la séquence
- Le résultat est une représentation enrichie de la séquence d'entrée (même nombre d'embeddings)

R. Grin

ML

93

93

Décodeur

- De base, prend une séquence de tokens et sort le token suivant (itérativement une séquence de tokens)
- Si traitement préalable par encodeur, utilise la représentation enrichie de la séquence d'entrée fournie par l'encodeur pour générer une séquence de sortie
- Génère la séquence de sortie token par token, en se basant sur les informations fournies par l'encodeur, et sur les tokens qu'il a déjà générés
- Pour chaque itération, les probabilités de tous les tokens du vocabulaire sont calculées et le transformeur en choisit un (le choix dépend des hyperparamètres)

R. Grin

ML

94

94

Encodeur ou/et décodeur

- Peuvent être utilisés indépendamment
- Modèles uniquement encodeurs : pour tâches qui nécessitent une compréhension de l'entrée, comme classification de phrases, analyse de sentiments, recherche de mots masqués
- Modèles uniquement décodeurs : pour tâches génératives telles que la génération de texte
- Modèles encodeurs-décodeurs : pour tâches génératives qui nécessitent une entrée, telles que la traduction ou le résumé de texte

R. Grin


ML

95

95

Travail préparatoire pour encodeur et décodeur

1. Séquence d'entrée est découpée en tokens
2. Chaque token est transformé en embedding, vecteur numérique de grande dimension
3. Tous les embeddings sont traités en parallèle ; l'encodage positionnel ajoute aux embeddings des informations sur la position des tokens



R. Grin

ML

96

Encodage positionnel

- Un grand avantage pour l'efficacité des transformeurs par rapport aux réseaux récurrents est qu'ils peuvent traiter en parallèle tous les embeddings en entrée
- Pour ne pas perdre la position de chaque token dans la séquence, cette information est codée dans un vecteur de même dimension que l'embedding, et ajoutée à l'embedding

R. Grin

ML

97

97

Addition et normalisation

- Chaque étape importante des encodeurs et décodeurs est suivie d'une étape d'addition et de normalisation
- **Addition** : ajoute aux embeddings des informations fournies par l'étape précédente (par exemple la couche d'attention) pour que cette information ne soit pas « oubliée » car déformée par la dernière étape
- **Normalisation** : il peut y avoir des variations importantes d'amplitude dans les valeurs fournies par les différentes étapes, ce qui peut fausser le travail effectué dans les étapes suivantes ; la normalisation contrôle ces variations

R. Grin

ML

98

98

Partie 1 : encodeur

Enrichit la séquence d'entrée

R. Grin


ML

99

99

Multi-head (ou self-) attention

- Etape très importante qui permet à l'encodeur de se concentrer sur les embeddings importants de la séquence d'entrée et de capturer à quel point chaque embedding est relié à chaque autre embedding
- A la sortie les embeddings sont enrichis avec l'attention



R. Grin

ML

100

100

Utilité de l'étape d'attention

- Sens des mots :
 - « Je n'ai pas pu aller à mon cours de batterie car la batterie de ma voiture est tombée en panne »
 - La seule façon de distinguer les 2 sens du mot « batterie » est d'analyser le contexte qui l'entoure ; l'attention le fait (relation de « batterie » avec « cours » ou bien avec « voiture »)
- Relation entre les mots :
 - « Jean a montré à Paul où il devait signer. »
 - L'attention va permettre d'associer « il » à Paul

R. Grin

ML

101

101

Pourquoi « plusieurs têtes » ?

- On peut prêter attention à plusieurs choses dans une phrase
- De plus, une phrase peut être ambiguë : « Robert a vu Bernard avec le télescope » peut avoir 2 sens
- Une tête d'attention va associer « Robert », « a vu » et « Bernard », alors qu'une autre tête va associer « Bernard » et « avec le télescope »
- Les différentes têtes peuvent identifier différentes relations entre les mots ; les embeddings capturent ces différentes interprétations qui pourront être résolues par la suite avec le contexte

R. Grin


ML

102

102

Réseau de neurones à propagation avant

7. Feed-forward layer : les embeddings contextuels (enrichis) sont transmis à un réseau de neurones
8. Le réseau de neurones permet d'extraire les caractéristiques de plus haut niveau, grâce à ses capacités linguistiques et à ses connaissances générales



R. Grin

ML

103

103

Partie 2 : décodeur

Génère la séquence de sortie, token par token, à partir de la séquence d'entrée enrichie par le travail de l'encodeur

R. Grin

ML

104

104

Globalement

- Au début du traitement, la séquence de sortie du décodeur est vide (en fait, elle contient un token spécial de début de séquence) ; elle se remplit au fur et à mesure du traitement
- Celui-ci génère alors le 1^{er} token qui est ajouté à la séquence de sortie du décodeur et on revient au début du traitement du décodeur
- Le décodeur génère ensuite le 2^{ème} token, ajouté lui aussi à la séquence de sortie, et ainsi de suite, jusqu'à ce que le décodeur génère un token d'arrêt

R. Grin


ML

105

105

Masked multi-head attention

- « Self-attention »
- Comme pour l'encodeur, ajoute des informations d'attention sur la séquence de sortie déjà générée pour comprendre les relations entre ses tokens
- « Masked » car, pendant l'entraînement, on masque les tokens qui suivent le dernier token généré pour simuler ce qui va se passer pendant l'inférence : à ce stade de la génération, on ne connaît pas les tokens à droite du dernier mot généré
- Par souci de consistance, cette étape est conservée pendant l'inférence



R. Grin


ML

106

106

Multi-head attention

- « Cross-attention » ; différente de « self-attention » car utilise la séquence de sortie déjà générée **et** la séquence d'entrée enrichie par l'encodeur (étape éliminée si pas d'encodeur)
- Enrichit les embeddings de la sortie du décodeur en intégrant ceux de l'entrée ; particulièrement utile pour les tâches de traduction



R. Grin


ML

107

107

Réseau de neurones

- En entrée, les embeddings enrichis par la couche d'attention
- La couche de sortie a autant de neurones que la dimension des embeddings utilisés
- Les valeurs de tous ces neurones de la couche de sortie décrivent à quoi va ressembler le prochain token (représentation riche et contextuelle de ce token)
- Les étapes suivantes vont permettre de calculer la distribution de probabilité des éléments du vocabulaire




R. Grin

ML

108

108

Linéarisation




- Prend en entrée l'embedding h , issu de la sortie du dernier bloc feed forward ; h est une représentation riche de l'embedding du token qui est attendu comme prochain token
- Permet de calculer le score (*logit*) de chaque élément du vocabulaire pour être le prochain token, en utilisant h et une matrice (apprise par rétropropagation), dite matrice de projection,

R. Grin ML 109

109

Softmax, probabilités de sortie



- Softmax : Fonction qui génère des probabilités à partir des logits; indique les chances que le modèle choisisse chaque token comme prochain token dans la séquence
- Prédiction prochain token peut être faite de plusieurs manières :
 - Choisir le token le plus probable
 - Choisir le token parmi les plus probables (le choix aléatoire se fait en tenant compte des probabilités)

R. Grin ML 110

110

Références

R. Grin ML 111

111

IA pour les décideurs

- Présentation de l'IA pour les décideurs (2021 ; UNESCO):
<https://unesdoc.unesco.org/ark:/48223/pf0000380006>

R. Grin ML 112

112

MOOCs gratuits

- L'Intelligence Artificielle... avec intelligence ! :
<https://www.fun-mooc.fr/fr/cours/lintelligence-artificielle-avec-intelligence/>
- Intelligence artificielle pour et par les enseignants :
<https://www.fun-mooc.fr/fr/cours/intelligence-artificielle-pour-et-par-les-enseignants-ai4t/>

R. Grin ML 113

113

- Lexique IA : <https://www.editions-eni.fr/lexique-intelligence-artificielle-chatgpt>
- Teachable machine de Google pour créer des modèles de ML rapidement et simplement, avec des images ou de l'audio, ou des poses (par exemple lever le bras) :
<https://teachablemachine.withgoogle.com/>

R. Grin ML 114

114

- Lexique IA : <https://www.editions-eni.fr/lexique-intelligence-artificielle-chatgpt>
- Teachable machine de Google pour créer des modèles de ML rapidement et simplement, avec des images ou de l'audio, ou des poses (par exemple lever le bras) : <https://teachablemachine.withgoogle.com/>

R. Grin

ML

115

115

Vidéo sur IA

- Vidéo de 2 h 45 très intéressante de Yann Lecun sur l'IA en général et les limites des LLMs, en particulier des modèles non open source : <https://www.youtube.com/watch?v=5tivTLU7s4o>

R. Grin

ML

116

116

Vidéos pour machine learning

- <https://www.youtube.com/channel/UCtYLUtTgS3kiFg4ystAhLbw> ; StatQuest essaie de vulgariser les statistiques et le machine learning
- <https://www.youtube.com/watch?v=trWrEWfhTVg> de David Louapre, sur le deep learning
- Tour d'horizon des modèles et algorithmes en 2 vidéos, avec des descriptions rapides de chaque modèle et algorithme ; Machine Learnia, Guillaume Saint-Cirgue : <https://www.youtube.com/watch?v=mT6NnslbNLM>

R. Grin

ML

117

117

Vidéos pour réseaux de neurones

- <https://www.youtube.com/watch?v=7ell8KEbhJo>, en français ; à voir pour commencer ; David Louapre
- <https://www.youtube.com/watch?v=XUFLq6dKQok> (Machine learnia), en français, une série pour étudier les algorithmes et mathématiques utilisés par IA

R. Grin

ML

118

118

- Cours coursera sur deep learning : <https://www.coursera.org/specializations/deep-learning> (accès gratuit pendant 7 jours seulement)
- Hugging Face, site Web pour ceux qui travaille avec le deep learning : <https://huggingface.co/>

R. Grin

ML

119

119

- <https://www.youtube.com/watch?v=rniEEd6M7fA> : courte vidéo qui explique rapidement le deep learning et qui utilise TensorFlow (bibliothèque qui permet de réaliser le réseau de neurones) et Keras (bibliothèque pour faire du deep learning en entraînant l'IA) ; fait partie de la série « Informatique sans complexe » qui contient d'autres vidéos courtes sur l'IA et sur divers autres domaines de l'informatique : <https://www.youtube.com/@InformatiqueSansComplexe>

R. Grin

ML

120

120

- Site Web Kaggle pour une communauté d'utilisateur de IA et de ML (Machine Learning). Pour apprendre (cours, guides), pour les développeurs, pour les chercheurs, et des projets sous la forme de compétitions ou autres formes.
<https://www.kaggle.com/>
- Article de vulgarisation très intéressant sur le phénomène de « grokking » :
<https://scienceetonnante.substack.com/p/grokking-les-modeles-dia-sont-ils>

R. Grin ML 121

121

Transformeurs (1/2)

- Cours Hugging Face : <https://huggingface.co/learn/nlp-course/chapter1/1>
- Visual Guide to Transformer Neural Networks :
https://www.youtube.com/playlist?list=PL86uXYUJ7999zE8u2-97i4KG_2Zpufkfb
- Le transformer illustré : <https://a-coles.github.io/2020/11/15/transformer-illustr.html> (en français), <https://jalammar.github.io/illustrated-transformer/>, en vidéo :
<https://www.youtube.com/watch?v=-QH8fRhfFHM>
- <https://lbourdois.github.io/blog/nlp/Transformer/>

R. Grin ML 122

122

Transformeurs (2/2)

- Article fondateur des transformeurs « Attention is all you need », <https://arxiv.org/abs/1706.03762>
- Article « The annotated transformer » qui illustre l'article avec du code en Python :
<https://nlp.seas.harvard.edu/2018/04/03/attention.html>
- Vidéo sur transformers, par Batool Haider :
https://www.youtube.com/playlist?list=PL86uXYUJ7999zE8u2-97i4KG_2Zpufkfb
- Article de Anthropic (LLM « Claude ») sur la « pensée » des LLMs : <https://www.anthropic.com/news/tracing-thoughts-language-model>

R. Grin ML 123

123